Data Wrangling
with pandas
Cheat Sheet
http://pandas.pydata.org

数据整理 –pandas数据处理的基础

整理后的数据集:

每一列是一个变量　　每一行是一条记录(observation)

数据整理辅助了pandas的向量操作. 当你操作变量的时候，pandas将自动保存记录(observation)，没有其他格式能比pandas更直观。

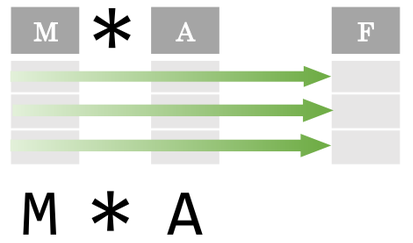

语法 – 创建DataFrame

	a	b	c
1	4	7	10
2	5	8	11
3	6	9	12

```
df = pd.DataFrame(
        {"a" : [4 ,5, 6],
         "b" : [7, 8, 9],
         "c" : [10, 11, 12]},
       index = [1, 2, 3])
```
为每一列指定值

```
df = pd.DataFrame(
    [[4, 7, 10],
     [5, 8, 11],
     [6, 9, 12]],
    index=[1, 2, 3],
    columns=['a', 'b', 'c'])
```
为每一行指定值

		a	b	c
n	v			
d	1	4	7	10
	2	5	8	11
e	2	6	9	12

```
df = pd.DataFrame(
        {"a" : [4 ,5, 6],
         "b" : [7, 8, 9],
         "c" : [10, 11, 12]},
index = pd.MultiIndex.from_tuples(
        [('d',1),('d',2),('e',2)],
          names=['n','v']))
```
创建多索引(MultiIndex)的DataFrame

链式调用

大多数pandas方法返回一个DataFrame对象，以便可以链式调用另一个方法，这提高了代码的可读性。

```
df = (pd.melt(df)
        .rename(columns={
                'variable' : 'var',
                'value' : 'val'})
        .query('val >= 200')
    )
```

数据重塑 – 改变数据集的布局

pd.melt(df)
将列数据平铺为行数据。

df.pivot(columns='var', values='val')
透视

pd.concat([df1,df2])
DataFrames的行拼接

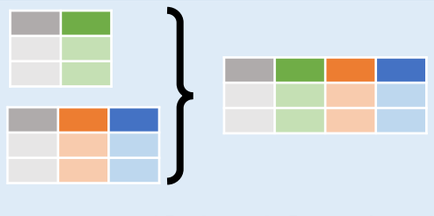

pd.concat([df1,df2], axis=1)
DataFrames的列拼接

df.sort_values('mpg')
按照某列的值进行行排序(升序)

df.sort_values('mpg',ascending=False)
按照某列的值进行行排序(降序)

df.rename(columns = {'y':'year'})
列名重命名

df.sort_index()
按索引排序

df.reset_index()
重置DataFrame的索引为行号，原索引变为普通列

df.drop(columns=['Length','Height'])
移除特定列

子集(行)

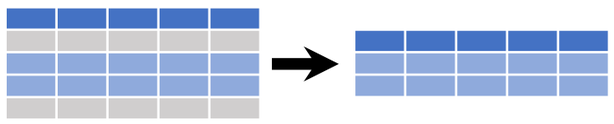

df[df.Length > 7]
筛选满足逻辑表达式的数据

df.drop_duplicates()
移除重复行 (仅考虑列)

df.head(n)
选择前n行

df.tail(n)
选择后n行

df.sample(frac=0.5)
随机选取指定比例的行

df.sample(n=10)
随机选取n行

df.iloc[10:20]
按位置选取行

df.nlargest(n, 'value')
按列值排序选取前n行

df.nsmallest(n, 'value')
按列值排序选取后n行

Python(pandas)中的逻辑运算			
<	小于	!=	不等于
>	大于	df.column.isin(*values*)	在...内，属于关系
==	等于	pd.isnull(*obj*)	值为null
<=	小于等于	pd.notnull(*obj*)	值非null
>=	大于等于	&,|,~,^,df.any(),df.all()	逻辑与,或,非,异或,存在,全部

子集(列)

df[['width','length','species']]
选取指定的多列

df['width'] *or* **df.width**
选取指定的单列

df.filter(regex='*regex*')
选取列名满足正则表达式的列

正则表达式示例	
'\.'	包含符号'.'
'Length$'	以字符串'Length'结尾
'^Sepal'	以字符串'Sepal'开头
'^x[1-5]$'	以字符串'x'开头且以字符串'1'或'2'或'3'或'4'或'5'结尾
'^(?!Species$).*'	除'Species'外的字符串

df.loc[:,'x2':'x4']
选取x2(含)和x4(含)之间的列

df.iloc[:,[1,2,5]]
选取下标为1,2,5的列(第一列下标为0)

df.loc[df['a'] > 10, ['a','c']]
选取满足逻辑表达式的行，但只返回指定列'a','b'

数据统计

df['w'].value_counts()
统计w列每一个值出现的次数，并降序排列
len(df)
返回DataFrame的行数
df['w'].nunique()
返回w列去重后值的个数
df.describe()
数据值列描述性汇总统计信息（GroupBy对象也有该方法）

pandas提供了大量的汇总函数（summary funcitons），它们对不同类型的pandas对象（DataFrame列，Series，GroupBy，Expanding和Rolling（见下文））进行操作，并为每个group生成单个值。作用于DataFrame时，返回结果是Series对象。

sum()
求和
count()
统计non-NA/null值的个数.
median()
计算中位数
quantile([0.25,0.75])
计算p分位数的值
apply(*function*)
将传入函数作用于每个对象

min()
求最小值
max()
求最大值
mean()
求平均值
var()
求方差
std()
求标准差

处理缺失值

df.dropna()
去掉含有NA值的行
df.fillna(value)
将所有的NA/null值替换为value

添加新列

df.assign(Area=lambda df: df.Length*df.Height)
计算并添加一列或多列
df['Volume'] = df.Length*df.Height*df.Depth
添加一列
pd.qcut(df.col, n, labels=False)
根据值的频率将数据分为n组，返回值为分组下标

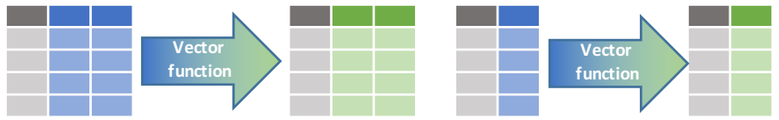

pandas提供了大量的向量函数（vector functions），可以作用于DataFrame的所有列或单个选定列（Series对象）。这些函数为每个列生成值向量。例子：

max(axis=1)
求每行最大值(axis可指定)
clip(lower=-10,upper=10)
将边界值外的值置为边界值

min(axis=1)
求最小值
abs()
求绝对值

合并数据集

adf

x1	x2
A	1
B	2
C	3

bdf

x1	x3
A	T
B	F
D	T

Standard Joins

x1	x2	x3
A	1	T
B	2	F
C	3	NaN

pd.merge(adf, bdf, how='left', on='x1')
bdf与adf合并，以adf为基准

x1	x2	x3
A	1.0	T
B	2.0	F
D	NaN	T

pd.merge(adf, bdf, how='right', on='x1')
adf与bdf合并，以bdf为基准

x1	x2	x3
A	1	T
B	2	F

pd.merge(adf, bdf, how='inner', on='x1')
合并数据，保留x1列的值均存在的行

x1	x2	x3
A	1	T
B	2	F
C	3	NaN
D	NaN	T

pd.merge(adf, bdf, how='outer', on='x1')
合并数据，保留所有行，所有数据

Filtering Joins

x1	x2
A	1
B	2

adf[adf.x1.isin(bdf.x1)]
返回adf满足过滤条件的行(x1在bdf.x1存在)

x1	x2
C	3

adf[~adf.x1.isin(bdf.x1)]
返回adf满足过滤条件的行(x1在bdf.x1不存在)

ydf

x1	x2
A	1
B	2
C	3

zdf

x1	x2
B	2
C	3
D	4

Set-like Operations

x1	x2
B	2
C	3

pd.merge(ydf, zdf)
同时出现在ydf和zdf的行(交集)

x1	x2
A	1
B	2
C	3
D	4

pd.merge(ydf, zdf, how='outer')
出现在ydf或zdf的行(并集)

x1	x2
A	1

pd.merge(ydf, zdf, how='outer', indicator=True)
.query('_merge == "left_only"')
.drop(columns=['_merge'])
在ydf出现但不在zdf出现的行(差集)

数据分组

df.groupby(by="col")
返回GroupBy对象
按'col'列的值进行分组

df.groupby(level="ind")
返回GroupBy对象
按'ind'的index进行分组
常用于MultiIndex场景下

上文所述的所有的汇总函数(summary functions)都能用于group
其他的GroupBy对象函数:
size()
每个group的大小
agg(*function*)
使用function对group进行聚合

下面的例子也能用于group，在这种场景下，这些方法作用于group的每一项，返回的向量长度与原DataFrame一致。

shift(1)
对数据进行移位
rank(method='dense')
排名，同值同排名，紧凑排名
rank(method='min')
排名，同值同排名，每次增加1
rank(pct=True)
排名，结果映射到[0, 1]
rank(method='first')
排名，值相同时按出现顺序排

shift(-1)
对数据进行反向移位
cumsum()
累加
cummax()
累计最大值
cummin()
累计最小值
cumprod()
累乘

窗口

df.expanding()
返回一个Expanding对象，在该窗口内，可以累计作用汇总函数(summary functions)
df.rolling(n)
返回一个Rolling对象，在长度为n的滚动窗口内，作用汇总函数。

绘图

df.plot.hist()
直方图(按列)

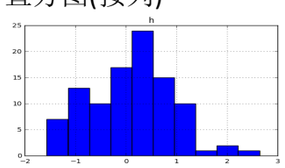

df.plot.scatter(x='w',y='h')
散点图